

Modelo Preditivo

Relatório final



Inteligência Artificial

Professora Filipa Peleja

Elementos do grupo:

Paulo Jadaugy nº 20241711

Emanuel Carvalho nº 20231627

Rui Outeiro nº 20231566

Engenharia Informática

3º Ano

Índice

Introdução	3
Problema.....	3
Solução Proposta.....	3
Fundamentação Técnica do Modelo.....	4
Arquitectura do Modelo PhotoperiodNet	5
Dados e Processo de Treinamento.....	6
Treinamento e Otimização	6
Métricas de Avaliação.....	6
Resultados experimentais	6
Limitações e Trabalho Futuro.....	9
Conclusão	9

Introdução

O módulo de IA do AquaSense foi pensado e desenvolvido para otimizar automaticamente as condições do aquário através da análise de dados de sensores em tempo real. O sistema recebe três entradas (turbidez, pH, temperatura) e produz três saídas acionáveis (ajuste de fotoperíodo, TPA recomendada, ajuste de alimentação).

Problema

Nos queremos resolver o problema dos utilizadores sem experiência que enfrentam dificuldades em gerir múltiplos parâmetros ao mesmo tempo com o seu aquário. A turbidez elevada pode indicar excesso de luz e algas, mas também excesso de alimentação ou necessidade de TPA. O nosso modelo de IA visa resolver este problema analisando todos os parâmetros simultaneamente e tomando decisões para melhorar a vida dos peixes.

Solução Proposta

Uma rede neural multi-output treinada com dados sintéticos baseados em regras de aquarofilia. O modelo aprende relações não-lineares entre os parâmetros e generaliza para cenários não vistos durante o treino.

Para isto utilizamos técnicas de AI para ultrapassar as limitações de abordagens baseadas em regras fixas. As redes neurais artificiais são adequadas para o nosso problema porque conseguem:

Modelar relações não-lineares entre variáveis, integrar múltiplos sensores em simultâneo e generalizar para situações não observadas durante o treino

Adotamos uma rede neural multi-output, o que nos permitiu gerar várias recomendações a partir do mesmo conjunto de entradas, de forma eficiente e coerente.

Fundamentação Técnica do Modelo

O problema abordado é de regressão supervisionada multivariada, onde se usa um conjunto de variáveis contínuas de entrada e é mapeado para várias saídas numéricas relacionadas. Escolhemos uma rede neural feedforward por se aproximar de funções contínuas e tendo em conta a natureza do projecto é bastante adequada para se modelar as relações não lineares entre os parâmetros físicos e as decisões operacionais do aquário.

Nas camadas ocultas usamos funções de activação ReLU, que dão não linearidade ao modelo e evitam problemas de saturação do gradiente.

A escolha pela ReLU melhora bastante a estabilidade do treino e além disso também acaba por reduzir o custo computacional, o que é ideal para redes que não são muito profundas como esta dada a natureza do projecto.

Já para as camadas de saída a opção foi a função sigmoid. Como ela limita os valores "ali" no intervalo $(0,1)$, isto permite-nos normalizar as previsões de forma directa. facilita imenso a interpretação dos resultados e garante que as saídas respeitam os limites operacionais que definimos, sem precisarmos de fazer pós processamento extra.

A normalização das variáveis de entrada foi feita com base no princípio de que os gradientes mais equilibrados levam a uma optimização mais eficiente. ao tirarmos as diferenças de escala entre as features, o processo de treino torna-se muito mais estável. Como função de perda usamos o "Mean Squared Error", porque mede logo o erro quadrático entre os valores previstos e os reais, o que é perfeito para problemas de regressão contínua. O optimizador Adam faz a combinação da taxa de aprendizagem adaptativa com momentum, o que permite uma convergência mais rápida e o modelo não fica tão sensível à escolha dos hiperparâmetros.


Também aplicamos técnicas de regularização como o dropout, para reduzir a co adaptação de neurónios, e o early stopping, que trava o treino quando o erro de validação deixa de baixar. Estas opções, ajudam a controlar o overfitting, que é super relevante quando se está a trabalhar com dados sintéticos.

Normalizámos as variáveis de entrada, com base no princípio dos gradientes mais equilibrados levarem a uma optimização mais eficiente. O processo de treinamento torna-se muito mais estável quando as diferenças de escala entre as características são removidas. O Erro Quadrático Médio foi escolhido como a função de perda porque mede imediatamente o erro quadrático entre os valores previstos e os reais o que para nós é perfeito em problemas de regressão contínua. O optimizador Adam, depois implementa uma taxa de aprendizagem

adaptativa com momentum o que acaba por atingir uma convergência mais rápida mas menos sensibilidade aos hiperparâmetros que tínhamos escolhidos.

Arquitetura do Modelo PhotoperiodNet

O modelo PhotoperiodNet é uma rede neuronal que está totalmente ligada com as camadas partilhadas e com três cabeças de saída independentes.



Para evitar o overfitting, utilizamos regularização com Dropout ($p = 0,1$).

Dados e Processo de Treinamento

Usando 10.000 amostras sintéticas geradas através de regras especializadas de aquarismo, o modelo foi treinado nos dados de amostra mencionados acima.

Uma normalização Z-score foi usada para normalizar as variáveis de entrada. Os dados foram divididos em: 80% para treinamento e 20% para teste. A reprodutibilidade foi mantida usando uma semente fixa.

Treinamento e Otimização

O treinamento foi realizado usando uma função de perda de ajuste de problema de regressão chamada Erro Quadrático Médio (MSE). Selecionamos o Adam como nosso otimizador devido à sua rápida taxa de convergência e robustez. Todos os casos de treinamento foram realizados em mini-lotes de tamanho 32, e o early stopping foi feito para evitar o overfitting.


Métricas de Avaliação

A avaliação do modelo foi realizada pelas seguintes métricas: MAE (Erro Médio Absoluto) MSE (Erro Quadrático Médio) RMSE R^2 (Coeficiente de Determinação) Usamos essas métricas para avaliar a precisão e o aspecto de generalização do modelo. Resultados Experimentais Isso mostra que nosso modelo tem um bom desempenho: Com um erro médio de 0,20 h no ajuste do fotoperíodo Erro médio na recomendação de TPA e alimentação inferior a 2%.


E $R^2 = 0,96$, o que significa que o modelo explica 96% da variância nos dados.

Resultados experimentais

Distribuição de dados:



Métricas finais:




O nosso modelo apresentou um desempenho elevado:

Com Erro médio de 0.20 h no ajuste do fotoperíodo

Com Erro médio inferior a 2% nas recomendações de TPA e alimentação


E $R^2 = 0.96$, indicando que o modelo explica 96% da variância dos dados

Detalhes do treino:



Métrica	Valor
Épocas treinadas	139 (early stopping)
Tempo de treino	76,3 segundos
Melhor Val Loss	0,0005
Test MSE	0.0006

Comparação do modelo vs baseline (regras):



Limitações e Trabalho Futuro

Limitações

- Número reduzido de sensores
- Regras base genéricas

Trabalho Futuro

- Inclusão de novos sensores (micro e macronutrientes, oxigénio, dióxido de carbono)
- Personalização por tipo de aquário
- Análise de feedback do utilizador para treino com base em decisões pelo modelo

Conclusão

Para aplicar de maneira integrada, os conceitos teóricos abordados ao longo da cadeira de Inteligência Artificial, foi feito o desenvolvimento e avaliação de um modelo de rede neural de múltiplas saídas como descrito neste relatório.

A arquitetura PhotoperiodNet foi projetada para explorar aprendizagem supervisionada, funções de ativação não lineares, otimização de gradiente e técnicas de regularização em um problema de regressão multivariada.

Os resultados mostram que o modelo é capaz de aprender consistentemente as relações definidas pelas regras básicas utilizadas no processo de criação de dados, o que apresentou baixos valores de erro e boa capacidade de generalização dentro do domínio estudado.

Por fim, pode-se concluir que o trabalho atinge os objetivos pedagógicos desta cadeira, ao compreender efetivamente os fundamentos de Inteligência Artificial e fazer bom uso dele, em um problema coerente e bem definido.