

Modelo Preditivo

Relatório final

The logo for IADE (Instituto de Administração e Desenvolvimento Empresarial) is displayed in white, bold, sans-serif capital letters. It is centered within a black rectangular area that has a diagonal cut on its right side, creating a triangular shape.

Inteligência Artificial

Professora Filipa Peleja

Elementos do grupo:

Paulo Jadaugy nº 20241711

Emanuel Carvalho nº 20231627

Rui Outeiro nº 20231566

Engenharia Informática

3º Ano

Índice

Introdução	3
O Problema	Error! Bookmark not defined.
Dados	Error! Bookmark not defined.
O Modelo	Error! Bookmark not defined.
O Treino	Error! Bookmark not defined.
Resultados	Error! Bookmark not defined.
Resultados	Error! Bookmark not defined.
Produção	Error! Bookmark not defined.
Produção	Error! Bookmark not defined.

Introdução

O módulo de IA do AquaSense foi desenvolvido para otimizar automaticamente as condições do aquário através da análise de dados de sensores em tempo real. O sistema recebe três entradas (turbidez, pH, temperatura) e produz três saídas acionáveis (ajuste de fotoperíodo, TPA recomendada, ajuste de alimentação).

Problema

Utilizadores sem experiência enfrentam dificuldades em correlacionar múltiplos parâmetros interdependentes. A turbidez elevada pode indicar excesso de luz (algas), mas também excesso de alimentação ou necessidade de TPA. A IA resolve este problema analisando todos os parâmetros simultaneamente.

Solução Proposta

Uma rede neural multi-output treinada com dados sintéticos baseados em regras de aquarofilia. O modelo aprende relações não-lineares entre os parâmetros e generaliza para cenários não vistos durante o treino.

<i>Entrada</i>	<i>Intervalo</i>	<i>Descrição</i>
<i>Turbidez</i>	0-100%	Clareza da água (0 = cristalina)
<i>pH</i>	6.0-8.5	Acidez/alcalinidade
<i>Temperatura</i>	20-31°C	Temperatura da água

<i>Saída</i>	<i>Intervalo</i>	<i>Descrição</i>
<i>Ajuste Fotoperíodo</i>	-12 a 0h	Redução de horas de luz
<i>TPA</i>	0-100%	Troca parcial de água recomendada
<i>Alimentação</i>	0-100%	Porcentagem da alimentação normal

Fundamentos Teóricos de Redes Neurais

Neurónio Artificial

O neurónio artificial (perceptrão) é a unidade básica das redes neurais. Inspirado no neurónio biológico, realiza uma soma ponderada das entradas, adiciona um bias e aplica uma função de ativação.

Equação do Neurónio

$$y = f(\sum w_i x_i + b) = f(w^T x + b)$$

Onde: y = saída, x_i = entradas, w_i = pesos, b = bias, f = função de activação

Camadas Lineares (Fully Connected)

Uma **camada linear** (ou *dense layer*) é uma transformação afim que mapeia um vector de entrada para um vector de saída através de uma matriz de pesos W e um vector de bias b .

Transformação Linear

$$z = Wx + b$$

Onde: $z \in Rm = \text{saída}$, $W \in Rm \times n = \text{matriz de pesos}$, $x \in Rn = \text{entrada}$, $b \in Rm = \text{bias}$

Parâmetros treináveis: $m \times n + m = m(n + 1)$

Exemplo: A primeira camada do PhotoperiodNet é Linear(3, 32), com $3 \times 32 + 32 = 128$ parâmetros.

Funções de Ativação

As funções de ativação introduzem **não-linearidade**, permitindo que a rede aprenda relações complexas. Sem elas, múltiplas camadas lineares seriam equivalentes a uma única transformação linear.

ReLU (Rectified Linear Unit)

A função **ReLU** é a ativação mais usada em camadas ocultas devido à sua simplicidade e eficácia.

Função ReLU

$$ReLU(x) = \max(0, x) = \{ x, \text{se } x > 0; 0, \text{se } x \leq 0 \}$$

Domínio: $\mathbb{R}$ | **Imagem:** $[0, +\infty)$

Derivada: $f'(x) = 1 \text{ se } x > 0, f'(x) = 0 \text{ se } x \leq 0$

Derivada da ReLU

$$d/dx ReLU(x) = \{ 1, \text{se } x > 0; 0, \text{se } x \leq 0 \}$$

A derivada simples (0 ou 1) evita o *vanishing gradient problem* que afecta sigmoid/tanh em redes profundas.

Vantagens da ReLU:

- **Esparsidade:** Neurónios negativos = 0, criando representações esparsas eficientes
- **Gradiente não saturante:** Para $x > 0$, gradiente = 1 (treino mais rápido)
- **Computacionalmente eficiente:** Apenas uma comparação (vs. exponenciais na sigmoid)
- **Convergência 6x mais rápida** que tanh (Krizhevsky et al., 2012)

Desvantagens:

- **Dying ReLU:** Neurónios com entrada sempre negativa "morrem" (gradiente = 0 permanente)
- **Não centrada em zero:** Saídas ≥ 0 podem causar zig-zagging na optimização

Função Sigmoid

A **sigmoid** mapeia valores para (0, 1), ideal para probabilidades ou valores normalizados.

Função Sigmoid (Logística)

$$\sigma(x) = 1 / (1 + e^{-x})$$

Domínio: $\mathbb{R}$ | **Imagem:** (0, 1)

$$\sigma(0) = 0.5 \mid \lim_{x \rightarrow +\infty} \sigma(x) = 1 \mid \lim_{x \rightarrow -\infty} \sigma(x) = 0$$

Derivada da Sigmoid

$$\sigma'(x) = \sigma(x) \cdot (1 - \sigma(x))$$

Derivada máxima = 0.25 (quando $x = 0$). Este valor pequeno causa *vanishing gradient* em redes profundas, por isso usamos sigmoid apenas nas saídas.

Uso no PhotoperiodNet:

- **Ajuste:** $-\text{sigmoid}(x) \rightarrow [-1, 0] \times 12 = [-12h, 0h]$
- **TPA:** $\text{sigmoid}(x) \rightarrow [0, 1] \times 100 = [0\%, 100\%]$
- **Alimentação:** $\text{sigmoid}(x) \rightarrow [0, 1] \times 100 = [0\%, 100\%]$

Comparação de Funções de Ativação

Função	Fórmula	Intervalo	Derivada	Uso
ReLU	$\max(0, x)$	$[0, +\infty)$	0 ou 1	Camadas ocultas
Sigmoid	$1/(1 + e^{-x})$	$(0, 1)$	$\sigma(1 - \sigma)$	Saídas normalizadas
Tanh	$(e^x - e^{-x})/(e^x + e^{-x})$	$(-1, 1)$	$1 - \tanh^2$	RNNs
Leaky ReLU	$\max(\alpha x, x)$	$\mathbb{R}$	α ou 1	Evitar dying ReLU
Softmax	$e^{x_i}/\sum e^{x_j}$	$(0,1), \sum = 1$	complexa	Classificação

Backpropagation e Gradiente Descendente

O **backpropagation** calcula gradientes da loss em relação aos pesos, propagando o erro da saída para as camadas anteriores usando a regra da cadeia.

Regra da Cadeia

$$\partial L / \partial w = \partial L / \partial z \cdot \partial z / \partial w$$

O gradiente de L em relação a w é o produto dos gradientes ao longo do caminho computacional.

Actualização de Pesos (Gradient Descent)

$$w_{t+1} = w_t - \eta \cdot \partial L / \partial w_t$$

η (eta): learning rate (taxa de aprendizagem)

Se gradiente > 0, diminuimos w. Se gradiente < 0, aumentamos w.

Variantes do Gradient Descent

<i>Variante</i>	<i>Batch</i>	<i>Características</i>
<i>Batch GD</i>	Todo o dataset	Estável mas lento
<i>SGD</i>	1 amostra	Rápido mas ruidoso
<i>Mini-batch</i>	n amostras (32)	Equilíbrio - usado no PhotoperiodNet

Arquitectura do Modelo PhotoperiodNet